

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA KHOA HỌC MÁY TÍNH



UIT
TRƯỜNG ĐẠI HỌC
CÔNG NGHỆ THÔNG TIN

ĐỒ ÁN MÔN HỌC CS116.Q23

Hedge Fund: Time Series Forecasting

Giảng viên hướng dẫn: Ths. Nguyễn Đức Vũ, Ths. Đàm Vũ Trọng Tài

TP. HỒ CHÍ MINH, 2026

DANH SÁCH SINH VIÊN THỰC HIỆN

STT	Họ và tên	MSSV
1	Nguyễn Việt Hoàng	24520561

Mục lục

1	INTRODUCTION	3
1.1	Mô tả bài toán (Problem Description)	3
1.2	Thách thức toán học và lý do chọn đề tài	3
2	EXPLORATORY DATA ANALYSIS	5
2.1	Tổng quan về không gian dữ liệu	5
2.2	Phân phối của biến mục tiêu theo horizon	7
2.3	Phân tích tương quan đặc trưng	9
2.4	Bất đối xứng trọng số	10
3	DATA PREPROCESSING	11
3.1	Xử lý khuyết thiếu và data-leakage	11
3.2	Tối ưu hóa cấu trúc bộ nhớ	11
4	FEATURE ENGINEERING	13
4.1	Thống kê phân cấp (Hierarchical Target Encodings)	13
4.2	Đặc trưng động lượng và độ trễ	13
4.3	Mã hóa đặc trưng tần suất và tương tác	14
4.4	Đặc trưng chu kỳ và sự thay đổi theo thời gian	14
5	MÔ HÌNH HÓA VÀ TỐI ƯU (MODELLING & OPTIMIZATION)	16
5.1	Kiến trúc cơ sở: Vì sao chọn LightGBM?	16
5.2	Multi-Horizon Modelling	18
5.3	Dual-Level Ensemble Architecture	18
5.4	Time-Based Cross Validation	20
5.5	Tối ưu hóa mục tiêu và thiết kế hàm mất mát	21
6	TỔNG KẾT	23
6.1	Tổng kết đồ án	23

Lời cảm ơn

Em xin trân trọng gửi lời cảm ơn đến giảng viên hướng dẫn, Ths. Nguyễn Đức Vũ và Ths. Đàm Vũ Trọng Tài, đã dành thời gian xem xét, góp ý và định hướng cho báo cáo này. Những nhận xét chuyên môn của thầy là cơ sở quan trọng giúp em hoàn thiện cách trình bày, củng cố lập luận nghiên cứu và nâng cao chất lượng nội dung của đề án.

Em cũng xin chân thành cảm ơn thầy vì đã tạo điều kiện để em tiếp cận bài toán dự báo chuỗi thời gian tài chính dưới góc nhìn học thuật và ứng dụng. Đây là nền tảng giúp em hiểu rõ hơn mối liên hệ giữa phương pháp học máy, phân tích dữ liệu và các yêu cầu thực tiễn trong lĩnh vực tài chính định lượng.

Chương 1: INTRODUCTION

1.1 Mô tả bài toán (Problem Description)



Đề án này lựa chọn cuộc thi *Hedge Fund: Time Series Forecasting* làm bối cảnh nghiên cứu để xây dựng một pipeline học máy phục vụ bài toán *large-scale hierarchical time-series forecasting*. Mục tiêu của hệ thống là dự đoán biến y_{target} , đại diện cho lợi nhuận đã được chuẩn hóa hoặc tín hiệu lợi nhuận của một danh mục đầu tư tài chính.

Tập dữ liệu được tổ chức theo cấu trúc phân cấp nhiều tầng, phản ánh mối quan hệ từ cấp độ tổng quát đến chi tiết. Cụ thể, `sub_category` đại diện cho các nhóm tài sản hoặc lĩnh vực đầu tư lớn, `code` biểu diễn các nhóm tài sản, trong khi `sub_code` dùng để định danh các thực thể chi tiết hơn bên trong từng nhóm. Bên cạnh đó, mỗi quan sát còn được gắn với chỉ số thời gian `ts_index` và giá trị `horizon`, thể hiện khoảng thời gian mà mô hình cần thực hiện dự báo.

Đặc điểm này khiến bài toán không chỉ mang tính chất dự báo chuỗi thời gian thông thường mà còn đòi hỏi mô hình phải khai thác hiệu quả các mối quan hệ phân cấp giữa các cấp dữ liệu, đồng thời thích ứng với số lượng lớn chuỗi cần dự báo trong môi trường tài chính thực tế.

Multi-Horizon Forecasting. Thay vì chỉ dự báo một time step, mô hình phải dự báo độc lập cho bốn horizon: 1, 3, 10 và 25. Các horizon ngắn như 1 và 3 phục vụ giao dịch ngắn hạn. Ngược lại, horizon 10 và 25 phù hợp hơn với các giao dịch trung hạn và dài hạn.

Về quy mô, tập train gồm 5,337,414 mẫu trải dài qua 3601 mốc thời gian, từ `ts_index` = 1 đến `ts_index` = 3601, với 94 đặc trưng ẩn danh. Tập test gồm 1,447,107 mẫu từ `ts_index` = 3602 đến `ts_index` = 4376, được dùng để đánh giá năng lực tổng quát hóa ngoài mẫu (out-of-sample) của hệ thống.

1.2 Thách thức toán học và lý do chọn đề tài

Ứng dụng học máy vào dữ liệu tài chính khác biệt đáng kể so với thị giác máy tính hay xử lý ngôn ngữ tự nhiên, vì dữ liệu thị trường thường có tỷ lệ nhiễu rất cao, tính biến thiên mạnh và mục tiêu đánh giá phụ thuộc trực tiếp vào trọng số của từng tài sản.

Thứ nhất, **tỷ lệ nhiễu cao** khiến các quy luật dự báo rất yếu và dễ bị ảnh hưởng bởi dao động ngẫu nhiên của dòng lệnh. Trong tài chính, một mô hình chỉ cải thiện xác suất dự báo thêm một biên rất nhỏ cũng có thể tạo ra lợi thế nếu được triển khai trên quy mô lớn và kiểm soát rủi ro tốt.

Thứ hai, **tính biến thiên và thị trường** làm cho các đặc tính thống kê như kỳ vọng và phương sai thay đổi theo thời gian. Một cú sốc vĩ mô, khủng hoảng thanh khoản hoặc sự kiện địa chính trị có thể làm quy luật trước đó mất hiệu lực. Do đó, pipeline cần được thiết kế để kháng nhiễu, hạn chế overfitting và đánh giá nghiêm ngặt theo trật tự thời gian.

Thứ ba, mục tiêu tối ưu không phải sai số trung bình thông thường, mà là **sai số có trọng số**. Một sai số nhỏ trên tài sản có thanh khoản hoặc tỷ trọng danh mục lớn có thể quan trọng hơn nhiều so với sai số lớn trên tài sản ít ảnh hưởng. Vì vậy, mô hình cần tối ưu theo Weighted RMSE để phản ánh đúng mục tiêu kinh tế của quỹ.

Chương 2: EXPLORATORY DATA ANALYSIS

Khám phá dữ liệu là bước quan trọng nhằm nhận diện cấu trúc dòng thông tin ẩn, đánh giá chất lượng dữ liệu và xác định các ràng buộc cần tuân thủ trước khi xây dựng mô hình.

2.1 Tổng quan về không gian dữ liệu

Dữ liệu được cung cấp dưới định dạng `.parquet`, gồm `train.parquet` và `test.parquet`. Mỗi mẫu chứa một khóa định danh `id`, được tạo bằng cách ghép các trường `code`, `sub_code`, `sub_category`, `horizon` và `ts_index`.

id	code	sub_code	horizon	ts_index	feature_a	...	y_target	weight
W2MW3G2L_J0G2B0KU_PZ9S1Z4V_25_89	W2MW3G2L	J0G2B0KU	25	89	29	...	-0.551324	40.982572
W2MW3G2L_J0G2B0KU_PZ9S1Z4V_1_89	W2MW3G2L	J0G2B0KU	1	89	53	...	-0.315583	150.075406
W2MW3G2L_J0G2B0KU_PZ9S1Z4V_3_89	W2MW3G2L	J0G2B0KU	3	89	51	...	-0.362894	115.953552
W2MW3G2L_J0G2B0KU_PZ9S1Z4V_10_89	W2MW3G2L	J0G2B0KU	10	89	44	...	-0.667023	64.573073
W2MW3G2L_J0G2B0KU_PZ9S1Z4V_25_90	W2MW3G2L	J0G2B0KU	25	90	28	...	-0.437398	41.948761


Hình 2.1: Tập train

id	code	sub_code	horizon	ts_index	feature_a	...	feature_cb	feature_ch
W2MW3G2L_495MGHFJ_PZ9S1Z4V_3_3647	W2MW3G2L	495MGHFJ	3	3647	95	...	-0.058961	2
W2MW3G2L_495MGHFJ_PZ9S1Z4V_10_3647	W2MW3G2L	495MGHFJ	10	3647	88	...	-0.058961	2
W2MW3G2L_495MGHFJ_PZ9S1Z4V_25_3647	W2MW3G2L	495MGHFJ	25	3647	71	...	-0.058961	2
W2MW3G2L_495MGHFJ_PZ9S1Z4V_1_3647	W2MW3G2L	495MGHFJ	1	3647	97	...	-0.058961	2
W2MW3G2L_495MGHFJ_PZ9S1Z4V_10_3648	W2MW3G2L	495MGHFJ	10	3648	87	...	-0.059835	2

Hình 2.2: Tập test


Các trường dữ liệu có thể chia thành bốn nhóm chính. Nhóm thứ nhất là cấu trúc phân cấp gồm `sub_category`, `code` và `sub_code`. Nhóm thứ hai là chiều thời gian gồm `ts_index` và `horizon`. Nhóm thứ ba là 94 alpha factors ẩn danh, từ `feature_a` đến `feature_ch`, đại diện cho các tín hiệu định lượng như biến động quá khứ, thanh khoản, khối lượng giao dịch hoặc mất cân bằng vi mô. Nhóm cuối cùng là `y_target` và `weight`; hai cột này chỉ tồn tại trong tập train và bị ẩn hoàn toàn trong tập test.

Không gian dữ liệu bao gồm 23 mã `code`, 180 mã `sub_code` và 5 nhóm `sub_category`. Tại mỗi mốc `ts_index`, trung bình có khoảng 387 công cụ tài chính được quan sát đồng thời.



Hình 2.3: Cấu trúc phân cấp của dữ liệu

Sự khác biệt giữa số lượng `sub_code` và số lượng mẫu đồng thời phản ánh quá trình ẩn danh hóa dữ liệu. Trong tập dữ liệu không tồn tại mã chứng khoán gốc; do đó, một `sub_code` có thể bao phủ nhiều mẫu tài sản khác nhau.




Hình 2.4: Số lượng công cụ giao dịch theo thời gian

2.2 Phân phối của biến mục tiêu theo horizon

Phân tích thống kê mô tả đối với y_{target} cho thấy mức độ biến động của biến mục tiêu gia tăng đáng kể khi horizon dự báo dài hơn. Trong tài chính định lượng, độ lệch chuẩn thường được sử dụng như một thước đo rủi ro vì phản ánh mức độ phân tán của kết quả thực tế quanh giá trị kỳ vọng. Bảng dưới đây tóm tắt kỳ vọng, độ lệch chuẩn, độ lệch và độ nhọn của biến mục tiêu theo từng horizon dự báo.


Horizon	Mean (Kỳ vọng)	Std (Độ lệch chuẩn)	Skewness (Độ lệch)	Kurtosis (Độ nhọn)
1	-0.08272	11.69969	5.280	528.473
3	-0.25241	19.36119	2.010	243.821
10	-0.77597	33.84206	0.828	176.820
25	-1.68188	52.82328	0.853	141.528

**Hình 2.5:** Phân phối biến mục tiêu theo horizon

Độ lệch chuẩn tăng từ 11.70 tại horizon 1 lên 52.82 tại horizon 25, tương đương mức tăng hơn 4.5 lần. Điều này cho thấy giá trị của biến mục tiêu có xu hướng dao động trong phạm vi rộng hơn khi khoảng thời gian dự báo được kéo dài, làm gia tăng tính bất định và độ khó của bài toán dự báo. Chẳng hạn, một tài sản có độ lệch chuẩn 50% thường được xem là rủi ro hơn một tài sản có độ lệch chuẩn 10% do lợi nhuận hoặc thua lỗ tiềm năng có thể biến động mạnh hơn đáng kể.

Bên cạnh đó, độ nhọn (kurtosis) duy trì ở mức rất cao trên mọi horizon, đặc biệt đạt 528.47 tại horizon 1, cho thấy phân phối có đuôi dày (fat tails) và xác suất xuất hiện các outlier lớn hơn đáng kể so với phân phối chuẩn. Giá trị skewness dương tại tất cả các horizon cũng phản ánh sự bất đối xứng của phân phối và sự tồn tại của các quan sát cực trị ở phía đuôi phải. Những đặc điểm này là điển hình của dữ liệu tài chính thực tế, nơi các cú sốc thị trường và các biến động bất thường xuất hiện thường xuyên hơn so với các giả định thống kê cổ điển. Do đó, các mô hình phi tuyến có khả năng xử lý nhiễu và ngoại lệ tốt như Gradient Boosting được kỳ vọng sẽ phù hợp hơn các mô hình hồi quy tuyến tính truyền thống.

Biến mục tiêu cũng thể hiện **phân cụm biến động** (volatility clustering), tức các giai đoạn biến động mạnh thường xuất hiện liên tiếp và xen kẽ với giai đoạn ổn định hơn.




Hình 2.6: Phân cụm biến động của biến mục tiêu

2.3 Phân tích tương quan đặc trưng

Để đánh giá mức độ liên hệ giữa đặc trưng và biến mục tiêu, đồ án sử dụng Hệ số Tương quan Hạng Spearman (Spearman Rank Correlation – IC) thay vì Pearson. Pearson chủ yếu đo quan hệ tuyến tính, trong khi Spearman đánh giá quan hệ đơn điệu, phù hợp hơn với dữ liệu tài chính nhiễu nhiễu và có cấu trúc phi tuyến.

Top các đặc trưng có trị tuyệt đối IC cao nhất ở horizon 1 so với y_{target} gồm **feature_ca** với 0.08513, **feature_u** với -0.08324, **feature_bz** với 0.08287 và **feature_am** với -0.08205. Dù các giá trị này nhỏ hơn 0.1, đây vẫn là mức có ý nghĩa trong các bài toán định lượng, nơi việc kết hợp nhiều tín hiệu yếu độc lập có thể tạo thành một meta-learner mạnh hơn.




Hình 2.7: Spearman IC của các đặc trưng

2.4 Bất đối xứng trọng số

Biến `weight` quy định mức độ ảnh hưởng của từng mẫu lên hàm mất mát. Giá trị trung bình của trọng số đạt 1.64×10^7 , trong khi giá trị lớn nhất lên tới 1.39×10^{13} . Điều này cho thấy dữ liệu có mức bất đối xứng rất lớn về tầm quan trọng kinh tế.

Đường cong Phân phối Tích lũy Trọng số (Weight Lorenz Curve)



Hình 2.8: Phân phối và đường Lorenz của trọng số

Đặc biệt, top 10% các mẫu có trọng số cao nhất chiếm khoảng 98.3% tổng trọng số của toàn bộ dataset. Vì vậy, nếu mô hình dự đoán sai trên nhóm này, hiệu quả danh mục có thể suy giảm nghiêm trọng. Trọng số buộc thuật toán ưu tiên các tài sản có ảnh hưởng lớn đến tổng giá trị tài sản ròng, thay vì tối ưu sai số trung bình trên mọi mẫu một cách đồng đều.

Chương 3: DATA PREPROCESSING

Tiền xử lý dữ liệu là bước đảm bảo chất lượng và tính hợp lệ của toàn bộ pipeline. Trong bối cảnh tài chính, mục tiêu không chỉ là làm cho dữ liệu có thể đưa vào thuật toán, mà còn phải bảo toàn thứ tự thông tin theo thời gian.

3.1 Xử lý khuyết thiếu và data-leakage

Trong y sinh hay thương mại điện tử, một số giá trị bị khuyết có thể được điền bằng nội suy (Interpolation), chẳng hạn lấy trung bình giữa mẫu đứng trước và mẫu đứng sau. Tuy nhiên, trong dữ liệu tài chính, việc sử dụng thông tin tại ngày $T + 1$ để lấp giá trị cho ngày T là lỗi nghiêm trọng gọi là **Look-ahead Bias**. Sai lệch này giúp mô hình đạt độ chính xác rất cao trên tập kiểm định, nhưng khi triển khai giao dịch thực tế lại thất bại vì tại thời điểm T , hệ thống không thể biết dữ liệu của ngày mai.

Vì vậy, bước xử lý khuyết thiếu được thiết kế theo nguyên tắc **Time-Wall Integrity**: mọi phép biến đổi chỉ sử dụng thông tin đã tồn tại tại hoặc trước thời điểm dự báo. Cách tiếp cận này giúp kết quả đánh giá phản ánh đúng điều kiện vận hành thực tế.

Giải pháp xử lý dữ liệu gồm ba lớp. Thứ nhất, LightGBM hỗ trợ học trực tiếp các nhánh tách cho giá trị khuyết (Missing value splits). Vì vậy, phần lớn các đặc trưng thô bị thiếu được giữ nguyên dưới dạng NaN; trong quá trình xây cây, thuật toán tự quyết định đẩy các mẫu này sang nhánh trái hoặc nhánh phải tùy theo hướng nào làm giảm hàm mất mát tốt hơn.

Thứ hai, với các đặc trưng kỹ thuật phụ thuộc chuỗi thời gian như moving average, rolling statistics hoặc lag-based features, hệ thống sử dụng `min_periods=1` trong các phép tính `rolling()`. Thiết lập này cho phép Pandas tính toán thống kê dựa trên bất kỳ số lượng mẫu quá khứ khả dụng nào, thay vì bắt buộc cửa sổ phải đầy đủ mới trả về kết quả.


Thứ ba, sau khi hoàn tất toàn bộ quá trình tạo đặc trưng, các giá trị khuyết còn sót lại, thường phát sinh từ `shift()`, được trung hòa bằng `fillna(0)`.

3.2 Tối ưu hóa cấu trúc bộ nhớ

Khối lượng dữ liệu 5.3 triệu dòng $\times$ 94 cột tương đương hơn 500 triệu điểm dữ liệu. Nếu sử dụng định dạng mặc định như `float64`, bộ nhớ cần thiết có thể lên tới hàng chục GB, đặc biệt khi feature engineering tạo thêm hàng trăm đặc trưng mới.

Thay vì chỉ dựa vào ép kiểu dữ liệu, hệ thống áp dụng chiến lược **quản lý bộ nhớ chủ động** gồm bốn thành phần chính. Thứ nhất là **train theo horizon**: dữ liệu được cô lập theo từng horizon `for h in [1, 3, 10, 25]`, giúp tại một thời điểm hệ thống chỉ xử lý một phần dữ liệu và giảm đáng kể RAM sử dụng.

Thứ hai là **hủy biến tức thời**. Các bảng tạm như `temp`, `train_h1` hoặc `temp_ch` được xóa bằng `del` ngay sau khi hoàn tất vai trò trung gian. Thứ ba là **cưỡng ép thu gom rác** bằng `gc.collect()` tại các điểm nghẽn bộ nhớ để thu hồi RAM từ các đối tượng đã bị xóa. Thứ tư là **tối ưu hóa biến giả**, trong đó one-hot encoding được tạo bằng `pd.get_dummies(dtype=int)` để tránh các mảng 64-bit không cần thiết.



Hình 3.1: Hiệu quả tối ưu hóa bộ nhớ

Chương 4: FEATURE ENGINEERING

4.1 Thống kê phân cấp (Hierarchical Target Encodings)

Dữ liệu của cuộc thi được tổ chức theo cấu trúc phân cấp gồm các cấp `code`, `sub_code` và `sub_category`. Để khai thác thông tin ở từng cấp độ, pipeline xây dựng các đặc trưng thống kê lịch sử như `code_mean`, `code_std`, `sub_code_mean`, `sub_code_std`, `sub_cat_mean` và `sub_cat_std`. Các đặc trưng này cung cấp thông tin về mức độ trung bình và độ phân tán của biến mục tiêu trong từng nhóm, từ đó giúp mô hình học được các khác biệt mang tính cấu trúc giữa các tài sản.

Các thống kê được tính theo nguyên tắc target encoding (mã hóa dựa trên biến mục tiêu):

$$Mean_{cat} = \frac{1}{|T_{train}|} \sum_{t \in T_{train}} y_{i,t}, \quad i \in cat.$$

Trong công thức này:

- $Mean_{cat}$: Giá trị mục tiêu trung bình của một nhóm cụ thể (như một `code` hoặc `sub_category`).
- $|T_{train}|$: Số lượng các quan sát trong tập dữ liệu huấn luyện thuộc nhóm đó.
- $y_{i,t}$: Giá trị mục tiêu (`y_target`) của tài sản i tại thời điểm t .

Lý do sử dụng: Việc lấy trung bình này giúp mô hình nhìn thấy được hành vi lịch sử tổng quát của cả một nhóm tài sản, thay vì chỉ nhìn vào từng tài sản riêng lẻ. Điều này đặc biệt hữu ích khi một tài sản mới xuất hiện nhưng thuộc một nhóm đã biết, mô hình có thể dùng hành vi của nhóm để dự báo. Để đảm bảo tính khách quan và tránh hiện tượng rò rỉ dữ liệu (data leakage) – tức là vô tình đưa thông tin của tương lai vào quá trình huấn luyện – các thống kê này được tính toán nghiêm ngặt chỉ trên phần dữ liệu quá khứ.

4.2 Đặc trưng động lượng và độ trễ

Động lượng (momentum) là một trong những nhóm đặc trưng được sử dụng rộng rãi trong các bài toán dự báo chuỗi thời gian tài chính. Để mô tả diễn biến lịch sử của tín hiệu, pipeline tạo các đặc trưng độ trễ (lag features) như Lag_1 , Lag_3 , Lag_7 và Lag_{14} , tương ứng với giá trị của biến tại các thời điểm trước đó 1, 3, 7 và 14 chu kỳ.

Từ các đặc trưng độ trễ, hệ thống xây dựng thêm các chỉ báo động lượng (momentum) nhằm đo lường mức độ và tốc độ thay đổi của tín hiệu theo thời gian. Một ví dụ tiêu biểu là công thức tính tỷ lệ thay đổi:

$$Ratio_{1,7} = \frac{Lag_1 - Lag_7}{|Lag_7| + \epsilon}.$$

Trong đó:

- Lag_1 : Giá trị của tài sản ở chu kỳ ngay trước đó (gần nhất).
- Lag_7 : Giá trị của tài sản ở thời điểm cách đó 7 chu kỳ.
- ϵ (epsilon): Một hằng số cực nhỏ (ví dụ 10^{-6}) được cộng vào mẫu số để tránh lỗi chia cho 0 khi $Lag_7 = 0$.

Lý do sử dụng: Thay vì chỉ đưa giá trị thô cho mô hình, công thức này cung cấp trực tiếp thông tin về *gia tốc* của giá cả. Nó trả lời câu hỏi: "So với 7 ngày trước, giá trị hiện tại đang tăng hay giảm, và tăng/giảm với tốc độ bao nhiêu phần trăm?". Phép chia cho $|Lag_7|$ đóng vai trò chuẩn hóa, giúp mô hình có thể so sánh công bằng động lượng giữa một tài sản có giá trị lớn và một tài sản có giá trị nhỏ.

Ngoài các tỷ lệ động lượng, pipeline còn xây dựng các đặc trưng mô tả cường độ xu hướng và mức độ biến động của tín hiệu dựa trên các ý tưởng tương tự chỉ báo Average Directional Index (ADX). Các đặc trưng này bổ sung thông tin về độ mạnh của xu hướng thay vì chỉ phản ánh hướng biến động.

4.3 Mã hóa đặc trưng tần suất và tương tác

Mối quan hệ giữa đặc trưng đầu vào và biến mục tiêu có thể thay đổi theo từng tài sản và từng horizon dự báo. Để mô hình hóa sự khác biệt này, pipeline tạo khóa tương tác `Interaction_Key` bằng cách kết hợp `code` và `horizon`.

Mỗi khóa tương tác sau đó được mã hóa bằng phương pháp frequency encoding, trong đó giá trị đặc trưng tương ứng với số lần xuất hiện của cặp (`code`, `horizon`) trong tập dữ liệu train. Đặc trưng này cung cấp thông tin về mức độ phổ biến của từng nhóm tài sản và bổ sung tín hiệu thống kê cho mô hình.

4.4 Đặc trưng chu kỳ và sự thay đổi theo thời gian

Các chuỗi thời gian tài chính thường chứa những mẫu lặp lại theo nhiều thang thời gian khác nhau. Để khai thác các thành phần tuần hoàn này, pipeline xây dựng một tập đặc trưng thời gian từ biến `ts_index`.

Đối với các chu kỳ ngắn và trung hạn, hệ thống sử dụng phép chia lấy dư để xác định vị trí của mỗi quan sát trong chu kỳ:

$$ts_mod_7, \quad ts_mod_30, \quad ts_mod_90.$$

Đối với các chu kỳ dài hạn hơn (ví dụ chu kỳ 100 ngày hoặc 365 ngày), hệ thống sử dụng phương pháp mã hóa lượng giác:


$$Feature_{sin_100} = \sin\left(\frac{2\pi \cdot ts_index}{100}\right),$$

$$Feature_{sin_365} = \sin\left(\frac{2\pi \cdot ts_index}{365}\right).$$

Ở đây:

- π : Hằng số Pi (≈ 3.14159).
- `ts_index`: Chỉ số thứ tự thời gian hiện tại.
- Số chia (100 hoặc 365): Độ dài của chu kỳ cần mô phỏng.

Lý do sử dụng: Trục thời gian là một đường thẳng vô tận, nhưng nhiều quy luật tài chính lại mang tính tuần hoàn (ví dụ hiệu ứng cuối năm, cuối quý). Việc bọc thời gian vào hàm sin hoặc cos giúp uốn trục thời gian thành một vòng tròn. Điều này cực kỳ quan trọng vì nó báo cho thuật toán biết rằng ngày thứ 365 và ngày thứ 1 thực chất là rất gần nhau về mặt chu kỳ (giống như ngày 31 tháng 12 và ngày 1 tháng 1), điều mà biểu diễn số học tuyến tính không thể làm được.



Hình 4.1: Seasonality

Các hàm lượng giác biểu diễn chu kỳ dưới dạng liên tục và tuần hoàn, giúp các thời điểm ở cuối và đầu cùng một chu kỳ có biểu diễn gần nhau trong không gian đặc trưng. Điều này hỗ trợ mô hình học các mẫu lặp lại hiệu quả hơn so với cách biểu diễn tuyến tính thông thường.

Đặc trưng thời gian dài hạn

Bên cạnh các thành phần tuần hoàn, dữ liệu tài chính còn có tính không dừng (non-stationarity), nghĩa là phân phối dữ liệu và mối quan hệ giữa các biến có thể thay đổi theo thời gian. Để cung cấp thông tin về vị trí tương đối của mỗi quan sát trong toàn bộ chuỗi thời gian, pipeline bổ sung đặc trưng:

$$Feature_{log_time} = \log(1 + ts_index).$$

Trong đó log là logarit tự nhiên, và việc cộng thêm 1 để đảm bảo giá trị bên trong luôn dương (tránh $\log(0)$).


Lý do sử dụng: Thị trường tài chính liên tục thay đổi cấu trúc. Đặc trưng này giúp mô hình nhận thức được nó đang ở giai đoạn nào của tập dữ liệu. Việc dùng logarit thay vì dùng trực tiếp ts_index giúp nén các giá trị thời gian về sau lại gần nhau hơn, tránh việc giá trị đặc trưng trở nên quá lớn và làm lệch trọng số của mô hình mạng học máy.

Chương 5: MÔ HÌNH HÓA VÀ TỐI ƯU (MODELLING & OPTIMIZATION)

Chương này trình bày cách hệ thống chuyển các đặc trưng đã xây dựng thành dự báo định lượng. Trọng tâm của chương không chỉ là lựa chọn thuật toán mạnh, mà còn là cách tổ chức train để phù hợp với dữ liệu tài chính: tách riêng theo horizon, kiểm định theo thời gian, học tổ hợp để giảm nhiễu và tối ưu hàm mất mát có trọng số.

Với dữ liệu dạng bảng có nhiều tín hiệu ẩn danh và tỷ lệ nhiễu cao, các kiến trúc học sâu như LSTM hoặc Transformer không phải lúc nào cũng là lựa chọn tối ưu. Trong bối cảnh này, Gradient Boosting Trees thường ổn định hơn vì khai thác tốt quan hệ phi tuyến, xử lý dữ liệu thiếu hiệu quả và ít đòi hỏi giả định mạnh về cấu trúc chuỗi.

Cách tiếp cận của đề án này là incremental, phát triển dựa trên một phương pháp có sẵn nhưng kết quả chưa được tối ưu.



Hình 5.1: Quy trình train mô hình

5.1 Kiến trúc cơ sở: Vì sao chọn LightGBM?

Nhiều kiến trúc học máy có thể được áp dụng cho bài toán dự báo chuỗi thời gian, bao gồm cả các mô hình mạng nơ-ron và các phương pháp tăng cường cây quyết định (gradient boosting). Trong nghiên cứu này, Light Gradient Boosting Machine (LightGBM) được lựa chọn làm mô hình cơ sở nhờ khả năng xử lý hiệu quả dữ liệu bảng có số lượng đặc trưng lớn, tốc độ train cao và cơ chế kiểm soát độ phức tạp mô hình tương đối rõ ràng.

Ba cơ chế quan trọng giúp LightGBM phù hợp với bài toán dự báo trong cuộc thi này bao gồm:

1. Histogram-based Splitting

Thay vì tìm điểm chia trực tiếp trên toàn bộ các giá trị liên tục, LightGBM trước tiên rời rạc hóa (discretize) các đặc trưng thành một số lượng bin cố định. Quá trình tìm điểm chia sau đó được thực hiện trên các bin thay vì trên từng giá trị riêng lẻ. Cách tiếp cận này giúp giảm đáng kể chi phí tính toán và bộ nhớ khi train trên tập dữ liệu lớn. Đồng thời, việc gom các giá trị gần nhau vào cùng một bin cũng làm giảm ảnh hưởng của nhiễu và các dao động nhỏ trong dữ liệu.


2. Gradient-based One-Side Sampling (GOSS)

Trong quá trình train, không phải mọi quan sát đều đóng góp như nhau vào việc cập nhật mô hình. GOSS ưu tiên giữ lại các mẫu có độ lớn gradient cao, tức những quan sát mà mô hình hiện tại dự báo chưa tốt, đồng thời chỉ lấy ngẫu nhiên một phần các mẫu có gradient nhỏ. Nhờ tập trung vào các quan sát mang nhiều thông tin hơn, LightGBM có thể giảm chi phí train trong khi vẫn duy trì hiệu quả dự báo.

3. Leaf-wise Tree Growth

Khác với nhiều thuật toán boosting truyền thống sử dụng chiến lược phát triển cây theo từng tầng (level-wise growth), LightGBM áp dụng chiến lược phát triển theo lá (leaf-wise growth). Tại mỗi bước, thuật toán lựa chọn nút lá mang lại mức giảm hàm mất mát lớn nhất để tiếp tục phân tách. Cơ chế này thường cho phép mô hình học được các quan hệ phi tuyến phức tạp với số lượng nút ít hơn. Tuy nhiên, do cây có thể phát triển không cân bằng, các tham số như `max_depth` và `min_data_in_leaf` được sử dụng để kiểm soát độ phức tạp và hạn chế hiện tượng overfitting.

Bên cạnh hiệu năng dự báo, LightGBM còn cung cấp các thước đo độ quan trọng đặc trưng (feature importance), chẳng hạn như tổng gain mà mỗi đặc trưng đóng góp trong quá trình phân tách. Các thông tin này giúp phân tích những nhóm tín hiệu có ảnh hưởng lớn đến quyết định của mô hình, từ đó hỗ trợ việc đánh giá và diễn giải kết quả dự báo.



Hình 5.2: LightGBM Feature Importance

5.2 Multi-Horizon Modelling

Bài toán yêu cầu dự báo ở bốn horizon khác nhau: 1, 3, 10 và 25. Mỗi horizon phản ánh một cơ chế thị trường riêng. Horizon ngắn thường chịu ảnh hưởng mạnh của nhiễu vi cấu trúc và dòng lệnh tức thời, trong khi horizon dài hơn phản ánh xu hướng, tái cân bằng danh mục và thay đổi kỳ vọng rủi ro.


Vì vậy, thay vì train một mô hình hồi quy đa đầu ra cho cả bốn horizon, hệ thống sử dụng **Direct Multi-Step Forecasting**. Cụ thể, dữ liệu được tách theo horizon và train các cụm LightGBM độc lập:

- $M_{h=1}$: mô hình cho horizon rất ngắn, tập trung vào biến động vi cấu trúc.
- $M_{h=3}$: mô hình cho tín hiệu ngắn hạn và phản ứng nhanh của thị trường.
- $M_{h=10}$: mô hình cho nhịp trung hạn, phù hợp với quyết định định thời điểm và tái cân bằng.
- $M_{h=25}$: mô hình cho xu hướng dài hơn và thay đổi kỳ vọng ở cấp danh mục.

Cách tách này giúp mô hình ở horizon dài không bị chi phối quá mức bởi nhiễu ngắn hạn. Đồng thời, mỗi cụm mô hình có thể học bộ quy luật riêng phù hợp với khoảng thời gian dự báo của nó.

5.3 Dual-Level Ensemble Architecture

Để nâng cao độ ổn định của dự báo và giảm thiểu tác động của nhiễu trong dữ liệu tài chính, hệ thống không sử dụng một mô hình hay một quy trình duy nhất. Thay vào đó, đồ án thiết kế hai pipeline song song và kết hợp dự báo của chúng.



Hình 5.3: Workflow Pipeline

Multi-Seed Averaging để giảm phương sai

Trong dữ liệu tài chính, tỷ lệ nhiễu trên tín hiệu thường rất cao. Một cây quyết định có thể vô tình học phải tương quan giả chỉ vì cách dữ liệu được lấy mẫu ngẫu nhiên. Để hạn chế rủi ro này, với mỗi horizon dự báo, hệ thống train 5 mô hình LightGBM độc lập bằng 5 seed khác nhau:

$$\{42, 2024, 777, 1337, 9999\}.$$


Việc thay đổi seed tác động trực tiếp đến hai nguồn ngẫu nhiên của mô hình:

- **Row sub-sampling (bagging_fraction):** mỗi mô hình chỉ mẫu một tập con ngẫu nhiên của dữ liệu tại từng vòng lặp, ví dụ khoảng 70–75% số dòng.
- **Feature sub-sampling (feature_fraction):** mỗi cây chỉ sử dụng một phần đặc trưng khi tìm điểm chia, ví dụ khoảng 60–65% số cột.

Sự xáo trộn có kiểm soát này buộc các mô hình học những lát cắt khác nhau của dữ liệu. Dự báo nội bộ được tính bằng trung bình cộng:

$$\hat{Y}_{seed} = \frac{1}{5} \sum_{i=1}^5 LightGBM_{seed_i}(X).$$

Theo bias-variance trade-off, trung bình hóa nhiều mô hình có bias thấp nhưng variance cao giúp giảm phương sai dự báo. Nhờ đó, tín hiệu đầu ra mượt hơn và ít bị chi phối bởi một lần khởi tạo ngẫu nhiên cụ thể.



Hình 5.4: Ensemble Averaging

Thiết kế Parallel Pipelines

Ngay cả khi đã dùng Multi-Seed Averaging, mô hình vẫn có thể bị "mù quáng" nếu chỉ dựa vào một góc nhìn duy nhất từ việc tạo đặc trưng (feature engineering). Để hệ thống thực sự vững chãi, toàn bộ quá trình dự báo được chia làm hai pipeline riêng biệt, hoạt động song song bổ trợ cho nhau:

- **Pipeline v1 (Baseline):** Pipeline này chỉ sử dụng các đặc trưng cơ bản nhất, cốt lõi nhất như độ trễ (lags) và các chỉ số trung bình trượt (rolling windows). Đặc điểm của luồng này là ít bị nhiễu, tập trung vào việc nắm bắt xu hướng thị trường chung. Mặc dù không quá nhạy bén, nhưng nó tạo ra một dự báo an toàn và khó bị đánh lừa bởi những biến động bất thường (overfitting).

- **Pipeline v2:** Nó kế thừa toàn bộ kiến trúc của v1 nhưng được có thêm các kỹ thuật xử lý tín hiệu để bắt kịp các chuyển động vi mô của thị trường.

Các kỹ thuật được bổ sung riêng cho Pipeline v2 bao gồm:

- **Winsorisation:** Thuật toán này chủ động cắt gọt (clip) các giá trị vượt quá phân vị 1% và 99%. *Lý do:* Dữ liệu tài chính thường chứa những điểm outliers do lỗi dữ liệu hoặc sự kiện bất ngờ. Nếu giữ nguyên, mô hình sẽ bị bias.
- **Sign Features:** Chỉ quan tâm đến việc giá tăng hay giảm (dấu âm/dương), bỏ qua độ lớn của mức thay đổi. *Lý do:* Chiều hướng thay đổi thường ổn định và mang lại độ tin cậy cao hơn là độ lớn của mức thay đổi trong một thị trường nhiễu.
- **Z-scores phân cấp:** Thuật toán chuẩn hóa giá trị của một tài sản so với điểm trung bình của nhóm `sub_category` chứa nó. *Lý do:* Biến đổi này loại bỏ hiệu ứng chung của toàn thị trường, giúp mô hình thấy rõ mối quan hệ của tài sản đó so với các đối thủ cạnh tranh cùng ngành.
- **Đánh trọng số theo tính thời sự (Exponential Recency Weighting):** Đây là một kỹ thuật can thiệp trực tiếp vào quá trình huấn luyện bằng công thức:

$$Weight(t) = \exp\left(\lambda \cdot \frac{t - t_{min}}{t_{max} - t_{min}}\right)$$

Giải thích công thức: t là thời gian hiện tại, t_{min} và t_{max} là mốc thời gian cũ nhất và mới nhất trong tập huấn luyện. λ là hệ số điều chỉnh tốc độ tăng trọng số (trong đề án chọn $\lambda = 2.5$).

Lý do sử dụng: Đặc điểm của thị trường tài chính là những gì mới xảy ra sẽ có giá trị dự báo cao hơn những chuyện đã xảy ra từ lâu. Công thức hàm mũ (exp) giúp các mẫu dữ liệu ở quá khứ gần được nhân với một trọng số lớn hơn rất nhiều so với dữ liệu ở quá khứ xa, ép mô hình phải chú ý học từ những động thái mới nhất của thị trường.

Kết hợp dự báo (Blending)

Sau khi thu được dự báo từ hai quy trình trên, hệ thống tiến hành pha trộn (blend) theo tỷ lệ:


$$\hat{Y}_{final} = 0.6 \times \hat{Y}_{v2} + 0.4 \times \hat{Y}_{v1}.$$

Pipeline v2 rất nhạy với các thay đổi vi mô nhờ recency weighting và z-score phân cấp, nên được gán trọng số cao hơn là 60%. Tuy nhiên, sự nhạy bén này cũng có thể khiến Pipeline v2 phản ứng quá mạnh trước các cú sốc ngắn hạn, dẫn đến thiếu ổn định cục bộ. Vì vậy, 40% kết quả từ Pipeline v1 được giữ lại như một *anchor*, giúp duy trì xu hướng cơ bản của thị trường.

5.4 Time-Based Cross Validation

Trong các bài toán dữ liệu độc lập như bất động sản hoặc y tế, K-Fold CV thường được sử dụng. Tuy nhiên, trong dữ liệu tài chính, việc chia ngẫu nhiên có thể tạo rò rỉ thời gian: mô hình có thể học từ tương lai để dự báo quá khứ. Vì vậy, validation phải mô phỏng đúng quy trình triển khai thực tế, trong đó mô hình chỉ được học từ dữ liệu quá khứ và dự báo cho tương lai.

Giải pháp được sử dụng là **TimeSeriesSplit / Expanding Window Validation**. Cách chia này giữ nguyên trật tự thời gian và đánh giá mô hình trên các đoạn dữ liệu xảy ra sau tập train.

**Hình 5.5:** CV Split

Trong thực nghiệm, tập validation được chốt tại mốc $ts_index = 3500$:

- **Train:** $1 \leq ts_index \leq 3499$. Mô hình chỉ học từ lịch sử đến ngày 3499.
- **Validation:** $3500 \leq ts_index \leq 3601$. Tập này dùng để điều chỉnh siêu tham số và early stopping.
- **Test:** $3602 \leq ts_index \leq 4376$. Đây là môi trường out-of-sample tách biệt.

Nếu loss trên validation không cải thiện sau một số vòng lặp nhất định, cơ chế `early_stopping_rounds = 50` dừng train để tránh học thuộc nhiều của tập train. Nhờ vậy, quá trình đánh giá phản ánh tốt hơn khả năng tổng quát hóa ngoài mẫu.

5.5 Tối ưu hóa mục tiêu và thiết kế hàm mất mát

Tiêu chí đánh giá chính của cuộc thi là Weighted Root Mean Squared Error (WRMSE). Chỉ số này mở rộng RMSE truyền thống bằng cách gán trọng số khác nhau cho từng quan sát, cho phép một số mẫu đóng góp nhiều hơn vào điểm số đánh giá cuối cùng.

WRMSE được tính toán dựa trên công thức:

$$WRMSE = \sqrt{\frac{\sum_{i=1}^N w_i (y_i - \hat{y}_i)^2}{\sum_{i=1}^N w_i y_i^2}}$$

Trong công thức này, các thành phần đóng vai trò như sau:

- N : Tổng số lượng quan sát cần dự báo.
- y_i : Giá trị thực tế của tài sản thứ i .
- $\hat{y}_i$: Giá trị mà mô hình của chúng ta dự báo cho tài sản thứ i .
- $(y_i - \hat{y}_i)^2$: Bình phương sai số. Bình phương giúp phạt nặng hơn những dự đoán sai lệch lớn.
- w_i : Trọng số kinh tế của quan sát thứ i .
- Tử số $\sum w_i (y_i - \hat{y}_i)^2$: Tổng sai số bình phương có trọng số của toàn bộ mô hình.
- Mẫu số $\sum w_i y_i^2$: Tổng độ phân tán (phương sai) có trọng số của chính tập dữ liệu gốc.

Để phù hợp với tiêu chí đánh giá này, hệ thống sử dụng các trọng số mẫu trong quá trình train LightGBM. Khi đó, các quan sát có trọng số lớn sẽ đóng góp nhiều hơn vào hàm mất mát và có ảnh hưởng lớn hơn đến quá trình cập nhật mô hình. Ngược lại, các quan sát có trọng số nhỏ sẽ có tác động hạn chế hơn.

Việc sử dụng trọng số giúp mô hình tập trung nhiều hơn vào những quan sát quan trọng đối với tiêu chí đánh giá của cuộc thi. Điều này làm giảm sự khác biệt giữa mục tiêu train và mục tiêu đánh giá cuối cùng.

Ngoài ra, thành phần

$$\sum_{i=1}^N w_i y_i^2$$

đóng vai trò chuẩn hóa sai số theo quy mô của biến mục tiêu. Nhờ cơ chế này, WRMSE phản ánh mức sai lệch tương đối so với độ lớn chung của dữ liệu thay vì chỉ đo lường sai số tuyệt đối.

Do đó, WRMSE là một thước đo phù hợp để đánh giá hiệu năng dự báo trong bối cảnh các quan sát có mức độ quan trọng khác nhau. Việc train mô hình với cùng hệ trọng số được sử dụng trong quá trình đánh giá giúp cải thiện sự nhất quán giữa quá trình tối ưu hóa và tiêu chí chấm điểm của cuộc thi.

Chương 6: TỔNG KẾT

6.1 Tổng kết đồ án

đồ án đã xây dựng một quy trình phân tích định lượng hoàn chỉnh cho bài toán dự báo chuỗi thời gian phân cấp nhiều horizon. Các kết quả chính có thể tóm tắt như sau:

- **Kiểm soát rò rỉ dữ liệu:** toàn bộ bước tiền xử lý, tạo đặc trưng và validation được thiết kế theo thứ tự thời gian, giúp tránh look-ahead bias.
- **Tối ưu tài nguyên tính toán:** dữ liệu được xử lý hợp lý giúp tăng tốc quá trình training cũng như quản lý bộ nhớ tốt hơn.
- **Xây dựng đặc trưng có ý nghĩa:** hệ thống kết hợp đặc trưng phân cấp, độ trễ, động lượng, chu kỳ thời gian và tương tác giữa tài sản với horizon.
- **Mô hình hóa ổn định:** LightGBM được train theo từng horizon, kết hợp time-based validation và seed averaging ensemble để giảm phương sai dự báo.
- **Liên kết với mục tiêu đầu tư:** hàm mất mát có trọng số giúp mô hình ưu tiên các mẫu có tác động lớn hơn đến hiệu quả danh mục, thay vì chỉ tối ưu sai số trung bình.
- **Kết quả thực nghiệm:** hướng tiếp cận đạt **top 34** của cuộc thi, cho thấy pipeline có khả năng tổng quát hóa tốt trong bối cảnh dữ liệu tài chính nhiễu và khó dự báo.

33	▲ 275	Minchy Cheng		0.1630	1	4mo
34	▲ 370	Nguyễn Việt Hoàng		0.1629	3	2mo
35	▲ 370	George Ugboke		0.1627	7	4mo

Hình 6.1: Hướng tiếp cận đạt top 34 của cuộc thi

Giá trị chính của đồ án nằm ở tính hệ thống: EDA, tiền xử lý, đặc trưng, mô hình, validation và hàm đánh giá được kết nối thành một pipeline nhất quán. Nhờ đó, kết quả không chỉ phản ánh hiệu năng của một thuật toán riêng lẻ, mà còn thể hiện cách tổ chức toàn bộ quy trình dự báo sao cho phù hợp với ràng buộc thời gian và mục tiêu thực tế của tài chính định lượng.